

7^ο Εξάμηνο, 2024 - 2025

ΣΗΜΑΣΙΟΛΟΓΙΚΟΣ ΙΣΤΟΣ ΚΑΙ ΕΥΦΥΕΙΣ ΕΦΑΡΜΟΓΕΣ

Εργασία B: RDF4J / GraphDB

Ναλμπάντη Παναγιώτα, 4050
Παντελοπούλου Βασιλική, 4153

Περιεχόμενα

Γενικά.....	2
Επέκταση μοντέλου με RDF4J	2
Μετασχηματισμός από RDFS σε OWL.....	2
Ορισμός περιορισμών	2
owl:someValuesFrom	3
owl:allValuesFrom.....	3
owl:hasValue.....	3
Τύποι ιδιοτήτων	4
Συμμετρική ιδιότητα	4
Επιμεριστική ιδιότητα	4
Ανάστροφη ιδιότητα	4
Προσθήκη νέων αντικειμένων	4
Φόρτωση στην GraphDB	5
Φόρτωση του μοντέλου.....	5
Δημιουργία και εκτέλεση SPARQL ερωτημάτων	5
Ερώτημα #1.....	5
Ερώτημα #2.....	6
Ερώτημα #3.....	7
Ερώτημα #4.....	7
Ερώτημα #5.....	8
Εξαγωγή στατιστικών δεδομένων με RDF4J API	10
Συχνότητα εμφάνισης συγκεκριμένων ιδιοτήτων	10
Κατανομή τύπων αντικειμένων	11
Μέσος αριθμός συνδέσεων ανά αντικείμενο.....	12
Συνολικός αριθμός τριπλετών	12
Κατανομή τιμών για ιδιότητες	12
Συχνότητα χρήσης συγκεκριμένων κλάσεων.....	13

Γενικά

Στην παρούσα εργασία κληθήκαμε να πραγματοποιήσουμε τα εξής:

1. Επέκταση του μοντέλου RDFS που αναπτύχθηκε στην πρώτη εργασία, προγραμματιστικά με χρήση της γλώσσας προγραμματισμού Java και της RDF4J.
2. Φόρτωση του μοντέλου στην GraphDB για δημιουργία σημασιολογικής βάσης και εκτέλεσης SPARQL ερωτημάτων.
3. Εξαγωγή στατιστικών στοιχείων από το μοντέλο.

Το μοντέλο μας έχει σχέση με το διάστημα και την αστρονομία, και το αρχείο .ttl που το περιέχει υπάρχει στον φάκελο του GitHub repository ως «astronomy.ttl».

****Υποσημείωση:** Στο *GitHub repository* έγιναν τα *commits* μόνο από ένα άτομο. Ο λόγος είναι διότι λόγω δύσκολων συνθηκών η εργασία έγινε από έναν υπολογιστή, όμως με ομαδική εκπόνηση.

Επέκταση μοντέλου με RDF4J

Μετασχηματισμός από RDFS σε OWL

Για την μετατροπή του μοντέλου από RDFS σε OWL έγινε χρήση της RDF4J. Αρχικά, μετά την σύνδεση του κώδικα με το «ProjectB» repository στο GraphDB, ανοίγεται με ένα `InputStream` το αρχείο «astronomy.ttl» με σκοπό την ανάγνωσή του. Επιπλέον, δημιουργείται ένα καινούριο μοντέλο τύπου `TreeModel`, το `owlModel`, στο οποίο θα αποθηκευτεί το owl μοντέλο.

Για την διευκόλυνση της ανάγνωσης, ορίστηκαν χώροι ονομάτων για τα IRIs που χρησιμοποιούνται (`owl`, `rdfs`, `rdf`, `astronomy`, `xsd`). Στην συνέχεια, προστέθηκαν όλες οι τριπλέτες του μοντέλου μέσα στο `owlModel`. Οι μετασχηματισμοί που έπρεπε να γίνουν στο συγκεκριμένο μοντέλο ήταν οι εξής:

- `RDFS.CLASS` → `OWL.CLASS`
- `RDF.PROPERTY` → `OWL.OBJECTPROPERTY` ή `OWL.DATATYPEPROPERTY`

Έτσι, για την μετατροπή από `RDF.CLASS` σε `OWL.CLASS`, με την βοήθεια της `getStatements()` λάβαμε όλα τα `statements` που έχουν υποκείμενο τύπου `rdf.class`, τα αφαιρέσαμε από το `owlModel` και προσθέσαμε νέα με το ίδιο υποκείμενο και κατηγορήμα, και με αντικείμενο = `owl.class`.

Παράλληλα, για την μετατροπή της `rdf` ιδιότητας σε `owl` ιδιότητα αντικειμένου ή `datatype`, εφαρμόστηκε η ίδια διαδικασία. Για να εντοπίσουμε τον τύπο που πρέπει να πάρει μια ιδιότητα, με την βοήθεια της `getStatements()` λάβαμε τις τριπλέτες με κατηγορήμα = `rdfs.range`. Σε αυτές, έγινε έλεγχος, αν τα αντικείμενα τους ήταν τύπου `Literal` ή τύπου `Object`, και έτσι έγινε αλλαγή σε `owl.datatypeProperty` και `owl.objectProperty` αντίστοιχα.

Στην περίπτωση όπου κάποια ιδιότητα δεν έχει δηλωμένο `range`, η `default` ανάθεση τύπου είναι `owl:datatypeProperty`.

Μετά από την παραπάνω διαδικασία, το `owlModel` είναι μετασχηματισμένο σε `owl`. Για την διατήρησή του, δημιουργείται ένα αρχείο .ttl, «astronomyOWL.ttl», μέσα στο οποίο αποθηκεύεται το `owlModel`.

Ορισμός περιορισμών

Στο νέο μοντέλο έγινε προσθήκη έξι περιορισμών με την βοήθεια της RDF4J, οι οποίοι περιγράφονται παρακάτω. Για την δήλωση των περιορισμών έγινε χρήση του `blank node`.

owl:someValuesFrom

Ο περιορισμός `someValuesFrom` δηλώνει ότι μια ιδιότητα σχετίζεται τουλάχιστον με ένα αντικείμενο μιας συγκεκριμένης κλάσης. Οι δύο σχετικοί περιορισμοί που δηλώθηκαν στο μοντέλο μας είναι οι εξής:

- Κάθε κλάση τύπου `Star` στην ιδιότητα `influences` θα λαμβάνει τουλάχιστον μια τιμή από την κλάση `Planet`. Δηλαδή, αν ένα αστέρι ασκεί επιρροή σε αντικείμενα, τουλάχιστον ένα από αυτά θα είναι πλανήτης.

```
BNode restriction1 = Values.bnode();
owlModel.add(Star, RDFS.SUBCLASSOF, restriction1);
owlModel.add(restriction1, RDF.TYPE, OWL.RESTRICTION);
owlModel.add(restriction1, OWL.ONPROPERTY, influences);
owlModel.add(restriction1, OWL.SOMEVALUESFROM, Planet);

_:node1ih5dahhfx1 a owl:Restriction;
owl:onProperty astronomy:influences;
owl:someValuesFrom astronomy:Planet .
```

- Κάθε κλάση τύπου `StellarObject` στην ιδιότητα `surroundedBy` θα λαμβάνει τουλάχιστον μια τιμή από την κλάση `Moon`. Δηλαδή αν ένα αστρικό αντικείμενο περιτριγυρίζεται από αντικείμενα, τότε τουλάχιστον ένα από αυτά θα είναι φυσικός δορυφόρος (`Moon`).

```
BNode restriction2 = Values.bnode();
owlModel.add(StellarObject, RDFS.SUBCLASSOF, restriction2);
owlModel.add(restriction2, RDF.TYPE, OWL.RESTRICTION);
owlModel.add(restriction2, OWL.ONPROPERTY, surroundedBy);
owlModel.add(restriction2, OWL.SOMEVALUESFROM, Moon);

_:node1ih5dahhfx2 a owl:Restriction;
owl:onProperty astronomy:surroundedBy;
owl:someValuesFrom astronomy:Moon .
```

owl:allValuesFrom

Ο περιορισμός `allValuesFrom` δηλώνει ότι όλες οι τιμές μιας ιδιότητας πρέπει να ανήκουν σε μια συγκεκριμένη κλάση. Οι δύο σχετικοί περιορισμοί που δηλώθηκαν στο μοντέλο μας είναι οι εξής:

- Κάθε κλάση τύπου `PlanetaryObject` στην ιδιότητα `orbitsAroundStar` θα λαμβάνει τιμή μόνο από την κλάση `MainSequenceStar`. Δηλαδή, αν ένα πλανητικό αντικείμενο έχει τροχιά γύρω από ένα αστέρι, τότε αυτό το αστέρι θα είναι `MainSequenceStar`.

```
BNode restriction3 = Values.bnode();
owlModel.add(PlanetaryObject, RDFS.SUBCLASSOF, restriction3);
owlModel.add(restriction3, RDF.TYPE, OWL.RESTRICTION);
owlModel.add(restriction3, OWL.ONPROPERTY, orbitsAroundStar);
owlModel.add(restriction3, OWL.ALLVALUESFROM, MainSequenceStar);

_:node1ih5dahhfx3 a owl:Restriction;
owl:allValuesFrom astronomy:MainSequenceStar;
owl:onProperty astronomy:orbitsAroundStar .
```

- Κάθε κλάση τύπου `Planet` στην ιδιότητα `collidedWith` θα λαμβάνει τιμή μόνο από την κλάση `Comet`. Δηλαδή, αν ένας πλανήτης έχει συγκρουστεί με ένα αντικείμενο, τότε αυτό το αντικείμενο είναι κομήτης.

```
BNode restriction4 = Values.bnode();
owlModel.add(Planet, RDFS.SUBCLASSOF, restriction4);
owlModel.add(restriction4, RDF.TYPE, OWL.RESTRICTION);
owlModel.add(restriction4, OWL.ONPROPERTY, collidedWith);
owlModel.add(restriction4, OWL.ALLVALUESFROM, Comet);

_:node1ih5dahhfx4 a owl:Restriction;
owl:allValuesFrom astronomy:Comet;
owl:onProperty astronomy:collidedWith .
```

owl:hasValue

Ο περιορισμός `hasValue` δηλώνει ότι μια ιδιότητα έχει συγκεκριμένη τιμή. Οι δύο σχετικοί περιορισμοί που δηλώθηκαν στο μοντέλο μας είναι οι εξής:

- Κάθε κλάση τύπου `Planet` στην ιδιότητα `orbitsAroundStar` θα λαμβάνει την τιμή «Sun». Δηλαδή, αν ένας πλανήτης έχει τροχιά γύρω από ένα αντικείμενο, αυτό θα είναι ο ήλιος.

```
BNode restriction5 = Values.bnode();
owlModel.add(Planet, RDFS.SUBCLASSOF, restriction5);
owlModel.add(restriction5, RDF.TYPE, OWL.RESTRICTION);
owlModel.add(restriction5, OWL.ONPROPERTY, orbitsAroundStar);
owlModel.add(restriction5, OWL.HASVALUE, Sun);

_:node1ih5dahhfx5 a owl:Restriction;
owl:hasValue astronomy:Sun;
owl:onProperty astronomy:orbitsAroundStar .
```

- Κάθε κλάση τύπου Moon στην ιδιότητα partOfGalaxy θα λαμβάνει την τιμή «MilkyWay». Δηλαδή, αν ένας φυσικός δορυφόρος είναι μέρος ενός γαλαξία, αυτός ο γαλαξίας θα είναι ο MilkyWay.

```
BNode restriction6 = Values.bnode();
owlModel.add(Moon, RDFS.SUBCLASSOF, restriction6);
owlModel.add(restriction6, RDF.TYPE, OWL.RESTRICTION);
owlModel.add(restriction6, OWL.ONPROPERTY, partOfGalaxy);
owlModel.add(restriction6, OWL.HASVALUE, MilkyWay);
```

```
_:node1ih5dahhfx6 a owl:Restriction;
  owl:hasValue astronomy:MilkyWay;
  owl:onProperty astronomy:partOfGalaxy .
```

Τύποι ιδιοτήτων

Στο νέο μοντέλο ορίσθηκαν έξι τύποι ιδιοτήτων σε ιδιότητες με την βοήθεια της RDF4J, οι οποίοι περιγράφονται παρακάτω.

Συμμετρική ιδιότητα

Μια συμμετρική ιδιότητα P ορίζεται ως owl:SymmetricProperty και δηλώνει ότι αν για δύο αντικείμενα ισχύει [x:a x:P x:b] τότε ισχύει και [x:b x:P x:a]. Παρακάτω δίνονται οι δύο ιδιότητες που ορίσαμε ως συμμετρικές.

```
owlModel.add(connectedTo, RDF.TYPE, OWL.SYMMETRICPROPERTY);
owlModel.add(collidedWith, RDF.TYPE, OWL.SYMMETRICPROPERTY);
```

Επιμεριστική ιδιότητα

Μια επιμεριστική ιδιότητα ορίζεται ως owl:TransitiveProperty και δηλώνει ότι αν για τρία αντικείμενα ισχύει [x:a x:P x:b] και [x:b x:P x:c], τότε ισχύει και [x:a x:P x:c]. Παρακάτω δίνονται οι δύο ιδιότητες που ορίσαμε ως επιμεριστικές.

```
owlModel.add(influences, RDF.TYPE, OWL.TRANSITIVEPROPERTY);
owlModel.add(orbitsAround, RDF.TYPE, OWL.TRANSITIVEPROPERTY);
```

Ανάστροφη ιδιότητα

Οι ανάστροφες ιδιότητες ορίζονται ως owl:inverseOf και δηλώνουν ότι η μια είναι αντίστροφη της άλλης. Δηλαδή, αν για δύο ιδιότητες ισχύει [x:P1 owl:inverseOf x:P2] και [x:a x:P1 x:b] τότε ισχύει και [x:b x:P2 x:a]. Παρακάτω δίνονται οι ιδιότητες που ορίσαμε ως ανάστροφες.

```
owlModel.add(illuminatedBy, OWL.INVERSEOF, illuminates);
owlModel.add(hasArtificialSatellite, OWL.INVERSEOF, artificialSatelliteOf);
```

Προσθήκη νέων αντικειμένων

Για την προσθήκη νέων αντικειμένων στο μοντέλο δημιουργήθηκε η συνάρτηση *objectAddition()*. Μέσα σε αυτή, έγινε προσθήκη 10 αντικειμένων σε 5 κλάσεις. Οι κλάσεις στις οποίες προστέθηκαν τα αντικείμενα παρατίθενται παρακάτω:

1. UnmannedSpacecraft
2. Moon
3. Supernova
4. BlueGiantStar
5. SupermassiveBlackHole

Για την δημιουργία τους, αρχικά, δηλώθηκε το IRI τους. Στην συνέχεια, ορίστηκαν ο τύπος κλάσης του κάθε αντικείμενου, διάφορες ιδιότητες που έχουν και η ετικέτα τους. Όπου κρίθηκε απαραίτητο, προτέθηκαν τριπλέτες όπου τα νέα αντικείμενα λαμβάνουν ρόλο `object`, έτσι ώστε να «συνδεθούν» και με αυτόν τον τρόπο με άλλα ήδη υπάρχοντα αντικείμενα.

Φόρτωση στην GraphDB

Φόρτωση του μοντέλου

Για την φόρτωση του μοντέλου στην GraphDB χρησιμοποιήθηκε η RDF4J. Πρώτα απ' όλα δημιουργήθηκε ένα repository με όνομα ProjectB στο GraphDB, και μετά την ενημέρωση του μοντέλου (με τα παραπάνω) γίνεται η αποθήκευση του περιεχομένου του `owlModel` στο repository.

```
String repositoryName = "ProjectB";
HTTPRepository repository = new HTTPRepository( repositoryURL: "http://localhost:7200/repositories/" + repositoryName);

File rdfsFile = new File( pathname: "src/main/resources/astronomy1.ttl");
InputStream inputStream = new FileInputStream(rdfsFile);

try (RepositoryConnection connection = repository.getConnection()) {
    // ΦΟΡΤΩΣΗ ΤΟΥ ΜΟΝΤΕΛΟΥ ΣΤΟ GRAPHDB
    connection.clear();
    connection.begin();
    connection.add(owlModel);
    connection.commit();
}
```

Δημιουργία και εκτέλεση SPARQL ερωτημάτων

Δημιουργήσαμε πέντε ερωτήματα SPARQL, τα οποία αναδεικνύουν τις νέες δυνατότητες που προστέθηκαν, δηλαδή περιορισμούς, τύπους ιδιοτήτων και νέα αντικείμενα. Τα ερωτήματα υλοποιήθηκαν στην συνάρτηση `sparqlQueries()`.

Ερώτημα #1

```
PREFIX astronomy: <http://example.org/astronomy#>
SELECT ?planet (COUNT (?moon) AS ?moonCount)
?star
WHERE {
    ?planet a astronomy:Planet ;
            astronomy:orbitsAroundStar ?star .
    ?moon astronomy:orbitsAroundPlanet ?planet .
}
GROUP BY ?planet ?star
HAVING (?moonCount > 1)
ORDER BY DESC(?moonCount)
```

Κάθε οντότητα του τύπου `PlanetaryObject` που σχετίζεται μέσω της ιδιότητας `orbitsAroundStar` μπορεί να περιστρέφεται αποκλειστικά γύρω από οντότητες της κλάσης `MainSequenceStar`. Ο περιορισμός `owl:allValuesFrom` διασφαλίζει ότι τα δεδομένα μας είναι συνεπή με το μοντέλο, στο οποίο ορίζουμε ότι ένας πλανήτης μπορεί να περιστρέφεται μόνο γύρω από αστέρια της κλάσης `MainSequenceStar`. Το ερώτημα που χρησιμοποιούμε επαληθεύει αυτόν τον περιορισμό, εμφανίζοντας μια λίστα πλανητών με

τον αριθμό των φεγγαριών τους και το αστέρι γύρω από το οποίο περιστρέφονται. Τα αποτελέσματα εμφανίζονται σε φθίνουσα σειρά ώστε οι πλανήτες με τα περισσότερα φεγγάρια να εμφανίζονται πρώτοι.

QUERY #1		
Planet	Moon Count	Star

Jupiter	4	Sun
Saturn	2	Sun

Το αστέρι Sun είναι τύπου MainSequenceStar.

Ερώτημα #2

```
PREFIX astronomy: <http://example.org/astronomy#>
SELECT ?astrObject ?artSat
WHERE {
  ?artSat a astronomy:ArtificialSatellite.
  ?astrObject a astronomy:AstronomicalObject.
  ?artSat astronomy:artificialSatelliteOf ?astrObject.
}
ORDER BY (?artSat)
```

Η ιδιότητα `hasArtificialSatellite` ορίζεται ως η αντίστροφη της ιδιότητας `artificialSatelliteOf`. Αυτό σημαίνει ότι αν ένας τεχνητός δορυφόρος συνδέεται με ένα `AstronomicalObject` μέσω της ιδιότητας `artificialSatelliteOf`, τότε το `AstronomicalObject` συνδέεται με τον τεχνητό δορυφόρο μέσω της ιδιότητας `hasArtificialSatellite`. Στο μοντέλο, τα αντικείμενα χρησιμοποιούν μόνο την ιδιότητα `hasArtificialSatellite`. Το ερώτημα που χρησιμοποιούμε εμφανίζει μια λίστα από ζεύγη τεχνητών δορυφόρων και των αστρονομικών αντικειμένων γύρω από τα οποία περιστρέφονται, επιτρέποντας την επαλήθευση ότι όλες οι σχέσεις δηλώνονται σωστά και συμφωνούν με την αντίστροφη ιδιότητα. Τα αποτελέσματα ταξινομούνται αλφαβητικά βάσει του ονόματος των τεχνητών δορυφόρων.

QUERY #2	
Astronomical Object	Artificial Satellite

Venus	Akatsuki
Earth	GPS
Earth	Goes
Mars	InSight
Earth	Iridium
Mercury	MESSENGER

Ερώτημα #3

```
PREFIX astronomy: <http://example.org/astronomy#>
SELECT ?object ?type
WHERE {
  ?stellarObj a astronomy:StellarObject;
    astronomy:surroundedBy ?object.
  ?object a ?type.
  FILTER (?type = astronomy:Moon || ?type = astronomy:Planet)
}
LIMIT 10
```

Σύμφωνα με το μοντέλο, κάθε StellarObject πρέπει να περιβάλλεται τουλάχιστον από ένα Moon, όπως καθορίζεται από τον περιορισμό owl:someValuesFrom. Το ερώτημα που χρησιμοποιούμε επιτρέπει την επαλήθευση ότι οι σχέσεις surroundedBy στα δεδομένα συμφωνούν με τον περιορισμό, εφόσον δείχνει ότι υπάρχουν τόσο πλανήτες όσο και φεγγάρια που περιβάλλουν τα αστρικά αντικείμενα. Τελικά, εμφανίζονται τα 10 πρώτα ζεύγη ώστε να διευκολύνεται η ανάλυση.

QUERY #3	
Object	Type Of Object

EarthMoon	Moon
Enceladus	Moon
Europa	Moon
Ganymede	Moon
Phobos	Moon
Miranda	Moon
Triton	Moon
Titan	Moon
Earth	Planet
Mars	Planet

Ερώτημα #4

```
PREFIX astronomy: <http://example.org/astronomy#>
SELECT ?subject ?galaxy
WHERE {
  ?subject a astronomy:Moon;
    astronomy:partOfGalaxy ?galaxy;
    astronomy:observedByTelescope ?telescope.
  FILTER(?telescope = astronomy:HubbleSpaceTelescope)
}
ORDER BY DESC(?subject)
```


Σύμφωνα με το μοντέλο, κάθε Moon πρέπει να ανήκει στον γαλαξία MilkyWay, όπως ορίζεται από τον περιορισμό owl:hasValue. Το ερώτημα εντοπίζει φεγγάρια που παρατηρήθηκαν από το τηλεσκόπιο Hubble Space Telescope, καθώς και τον γαλαξία στον οποίο ανήκουν. Με αυτόν τον τρόπο, μπορούμε να επαληθεύσουμε αν τα δεδομένα μας συμφωνούν με τον περιορισμό. Τα αποτελέσματα ταξινομούνται σε φθίνουσα σειρά βάσει του ονόματος των φεγγαριών, ενώ επιστρέφουν πληροφορίες για τον γαλαξία στον οποίο ανήκουν, ο οποίος πρέπει να έχει την τιμή MilkyWay.

QUERY #4	
Subject	Galaxy

Titan	MilkyWay
Phobos	MilkyWay
Ganymede	MilkyWay
Europa	MilkyWay
Enceladus	MilkyWay
EarthMoon	MilkyWay

Ερώτημα #5

```
PREFIX astronomy: <http://example.org/astronomy#>
SELECT ?subject ?object
WHERE {
  ?subject a ?type ;
    astronomy:influences ?object.
  FILTER(?type = astronomy:Planet || ?type = astronomy:Moon)
}
ORDER BY(?subject)
```

Η ιδιότητα influences έχει οριστεί ως μεταβατική, γεγονός που σημαίνει ότι αν ένα αντικείμενο επηρεάζει ένα δεύτερο και αυτό με τη σειρά του επηρεάζει ένα τρίτο, τότε το πρώτο αντικείμενο θεωρείται ότι επηρεάζει και το τρίτο. Σύμφωνα με το μοντέλο, κάθε αστέρι Star πρέπει να επηρεάζει τουλάχιστον έναν πλανήτη Planet, όπως ορίζεται από τον περιορισμό owl:someValuesFrom. Το ερώτημα εξετάζει δεδομένα σχετικά με πλανήτες και φεγγάρια που επηρεάζουν άλλα αντικείμενα. Τα αποτελέσματα εμφανίζονται ταξινομημένα αλφαβητικά βάσει των υποκειμένων. Παράλληλα, επαληθεύει ότι τα δεδομένα μας συμφωνούν με τον περιορισμό.

Subject	Object
Callisto	Jupiter
Earth	Earth
Earth	EarthMoon
EarthMoon	Earth
EarthMoon	EarthMoon
Enceladus	Saturn
Enceladus	Enceladus
Enceladus	Titan
Europa	Jupiter
Ganymede	Jupiter
Io	Jupiter
Mars	Earth
Mars	Jupiter
Mars	EarthMoon
Miranda	Uranus
Phobos	Earth
Phobos	Mars
Phobos	Jupiter
Phobos	EarthMoon
Saturn	Saturn
Saturn	Enceladus
Saturn	Titan
Titan	Saturn
Titan	Enceladus
Titan	Titan
Triton	Neptune
Venus	Earth
Venus	EarthMoon

Για να διευκολυνθεί η ανάλυση δίνονται κάποια παραδείγματα που υπάρχουν στο αποτέλεσμα που επαληθεύουν την μεταβατική ιδιότητα που τέθηκε ως περιορισμός:

- astronomy:Enceladus astronomy:influences astronomy:Saturn
astronomy:Saturn astronomy:influences astronomy:Titan
astronomy:Enceladus astronomy:influences astronomy:Titan
- astronomy:Mars astronomy:influences astronomy:Earth
astronomy:Earth astronomy:influences astronomy:EarthMoon
astronomy:Mars astronomy:influences astronomy:EarthMoon
- astronomy:Venus astronomy:influences astronomy:Earth
astronomy:Earth astronomy:influences astronomy:EarthMoon
astronomy:Venus astronomy:influences astronomy:EarthMoon

Εξαγωγή στατιστικών δεδομένων με RDF4J API

Για την εξαγωγή στατιστικών δεδομένων από το μοντέλο owl δημιουργήθηκε η συνάρτηση *statistics()*. Για τους περισσότερους υπολογισμούς έγινε χρήση *HashMap<String, Integer>*, για την διευκόλυνση εξαγωγής αποτελεσμάτων. Οι υπολογισμοί έγιναν ταυτόχρονα σε μια *for loop*, η οποία ελέγχει κάθε *statement* που υπάρχει το *owlModel*. Παρακάτω περιγράφεται αναλυτικά η διαδικασία για την εξαγωγή αποτελέσματος κάθε ζητούμενου.

Συχνότητα εμφάνισης συγκεκριμένων ιδιοτήτων

Για να βρούμε την συχνότητα εμφάνισης ιδιοτήτων, υπολογίσαμε πόσες φορές χρησιμοποιείται κάθε ιδιότητα από αντικείμενα στο μοντέλο. Συγκεκριμένα, για κάθε *statement* προσθέσαμε το *predicate* του στο *HashMap propertyFreq*. Κάθε φορά που ένα *predicate* εισάγεται για πρώτη φορά στο *map*, η *default* τιμή του (*value*) είναι μηδέν, ενώ αν υπάρχει ήδη τότε αυξάνεται κατά ένα. Έτσι, στο τέλος, καταλήγουμε να έχουμε ζεύγη από *predicates* και συχνότητα εμφάνισής τους. Στα αποτελέσματα υπάρχουν φυσικά και οι ιδιότητες που προέκυψαν μετά από *reasoning* του *GraphDB*, όπως η *sameAs*.

```
// ΣΥΧΝΟΤΗΤΑ ΕΜΦΑΝΙΣΗΣ ΣΥΓΓΕΚΡΙΜΕΝΩΝ ΙΔΙΟΤΗΤΩΝ
propertyFreq.put(predicate, propertyFreq.getOrDefault(predicate, defaultValue: 0) + 1);
```

Αποτελέσματα:

Frequency of each property:			
Property	Frequency		

observedBy	28	hasArtificialSatellite	6
hasCrewCapacity	2	spectralType	15
discoveredBy	57	equivalentClass	2
hasGravity	36	visibleToNakedEye	14
launchDate	31	collidedWith	2
type	989	range	248
relatedTo	88	hasAltitudeFromEarth	2
launchedBy	8	discoveredDate	43
hasActiveStatus	31	illuminatedBy	27
interactsWith	1	hasMaxCoverage	4
wasObservedOn	14	subPropertyOf	86
passedNear	5	surroundedBy	26
subClassOf	249	hasDuration	14
hasOperator	31	influences	35
imports	1	hasPhysicalProperty	96
hasOrbitType	5	allValuesFrom	2
orbitsAroundStar	17	hasTemperature	54
equivalentProperty	12	partOfGalaxy	48
hasDiameter	54	observedFrom	14
hasMass	54	inverseOf	2
dockedAt	2	hasSatellite	8
causedBy	4	providesServiceTo	1
hasValue	2	hasOrbitalPeriod	27
versionInfo	1	label	191
hasLife	27	someValuesFrom	2
hasBrightness	9	orbitsAround	17
hasColor	8	hasSpin	7
visitedBy	24	observedByTelescope	46
orbitsAroundPlanet	10	hasFocalLength	5
hasGalacticCenter	4	visibleFrom	25
domain	318	sameAs	301
hasOrbitalSpeed	2		
onProperty	6		
monitors	1		
observedBySpacecraft	4		

Όπως παρατηρούμε, οι πιο συχνή ιδιότητα είναι η type, ακολουθούμενη από τις domain, sameAs και subClassOf. Οι πιο συχνές ιδιότητες που δημιουργήσαμε εμείς για το μοντέλο είναι οι hasPhysicalProperty και relateTo.

Κατανομή τύπων αντικειμένων

Για να κάνουμε κατανομή τύπων αντικειμένων, υπολογίσαμε πόσα αντικείμενα ανήκουν σε κάθε κλάση. Συγκεκριμένα, ελέγξαμε αν στο statement που επεξεργαζόμαστε κάθε φορά έχουμε ως κατηγορήμα το RDF.TYPE, το οποίο προδίδει τον ορισμό αντικειμένου. Για κάθε statement που είναι τέτοιας μορφής, πήραμε το object του, το οποίο είναι ουσιαστικά η κλάση στην οποία ανήκει το αντικείμενο. Το προσθέσαμε στο HashMap *numOfClassObjects*, και ως value του map ανανεώναμε κάθε φορά τον αριθμό εμφάνισής της κλάσης. Για να γίνει πιο ξεκάθαρο, μετρήσαμε πόσες φορές εμφανίζεται μια κλάση σε τριπλέτες τύπου [subject, rdf.type, class], διότι μια τέτοια τριπλέτα δηλώνει ένα αντικείμενο που ανήκει στην class. Στα αποτελέσματα υπάρχουν φυσικά και κλάσεις που προέκυψαν μετά από reasoning του GraphDB, όπως η AnnotationProperty και OntologyProperty.

```
// ΚΑΤΑΝΟΜΗ ΤΥΠΩΝ ΑΝΤΙΚΕΙΜΕΝΩΝ
if (statement.getPredicate().equals(RDF.TYPE)) {
    String objectIRI = statement.getObject().toString();
    String object = objectIRI.substring( beginIndex: objectIRI.lastIndexOf( ch: '#' ) + 1 );

    numOfClassObjects.put(object, numOfClassObjects.getOrDefault(object, defaultValue: 0) + 1);
}
```

Αποτελέσματα:

Number of objects that belong to each class:			
Class	# of Objects		

Galaxy	4	SymmetricProperty	2
AstronomicalObject	28	Comet	5
Telescope	5	LunarEclipse	2
SpaceStation	2	Class	112
Moon	10	WeatherSatellite	1
PlanetaryObject	17	SpaceObject	50
SpaceArtifact	22	Ontology	1
Eclipse	4	LongPeriodComet	2
Elliptical	2	GiantStar	1
TransitiveProperty	2	ContainerMembershipProperty	1
StellarBlackHole	2	CommunicationSatellite	1
DwarfPlanet	4	BlueSuperGiantStar	1
NavigationSatellite	1	Star	5
Datatype	34	BlueGiantStar	10
StellarObject	7	CelestialBody	24
MainSequenceStar	2	SuperGiantStar	2
List	1	RedGiantStar	1
Planet	8	Spacecraft	9
Thing	301	MannedSpacecraft	2
DatatypeProperty	42	ArtificialSatellite	6
Supernova	10	BlackHole	2
ShortPeriodComet	3	Spiral	2
ObjectProperty	128	AstronomicalPhenomenon	4
RedSuperGiantStar	1	Restriction	6
OntologyProperty	5	SolarEclipse	2
Resource	55	AnnotationProperty	9
UnmannedSpacecraft	16		
SupermassiveBlackHole	10		

Όπως παρατηρούμε, τα περισσότερα αντικείμενα είναι τύπου Thing (που προϋπήρχε στο μοντέλο από το TopBraid). Τα περισσότερα αντικείμενα σε κλάση που εμείς έχουμε ορίσει είναι τύπου SpaceObject.

Μέσος αριθμός συνδέσεων ανά αντικείμενο

Για να βρούμε τον μέσο αριθμό συνδέσεων ανά αντικείμενο, υπολογίσαμε τον μέσο αριθμό των ιδιοτήτων που έχει κάθε αντικείμενο. Συγκεκριμένα, κρατήσαμε στο HashMap *subjectConnections* τα αντικείμενα και τον αριθμό εμφάνισής τους σε statements ως subject. Με την βοήθεια του *size()* βρήκαμε τον συνολικό αριθμό των (distinct) subjects που υπάρχουν στο map, και στην συνέχεια, αθροίσαμε τις συνδέσεις όλων των αντικειμένων. Ο μέσος όρος προκύπτει από τον λόγο του αθροίσματος των συνδέσεων προς τον συνολικό αριθμό αντικειμένων.

```
// ΜΕΣΟΣ ΑΡΙΘΜΟΣ ΣΥΝΔΕΣΕΩΝ ΑΝΑ ΑΝΤΙΚΕΙΜΕΝΟ
String subjectIRI = statement.getSubject().toString();
String subject = subjectIRI.substring( beginIndex: subjectIRI.lastIndexOf( ch: '#' ) + 1 );
subjectConnections.put(subject, subjectConnections.getOrDefault(subject, defaultValue: 0) + 1);
```

(έξω από την for loop:)

```
double numOfSubjects = subjectConnections.size();
Integer sumOfConnections = 0;
for (Integer connection : subjectConnections.values()) {
    sumOfConnections += connection;
}
double connection_avg = numOfSubjects > 0 ? sumOfConnections / numOfSubjects : 0;
```

Αποτελέσματα:

```
Average number of connections per object: 9,93
```

Συμπεραίνουμε ότι το μοντέλο δεν είναι ιδιαίτερα πολύπλοκο, αφού τα περισσότερα αντικείμενα έχουν περίπου 10 ιδιότητες, αριθμός που δεν θεωρείται πολύ μεγάλος.

Συνολικός αριθμός τριπλετών

Για τον υπολογισμό του συνολικού αριθμού τριπλετών του μοντέλου, κρατήσαμε έναν μετρητή μέσα στην for loop, ο οποίος αυξάνεται κατά 1 κάθε φορά, ώστε στο τέλος να είναι ίσος με τον αριθμό των statements.

```
// ΣΥΝΟΛΙΚΟΣ ΑΡΙΘΜΟΣ ΤΡΙΠΛΕΤΩΝ
numOfTriplets += count;
```

Αποτελέσματα:

```
Total number of triplets: 3505
```

Όπως βλέπουμε, το μοντέλο μας είναι αρκετά μεγάλο σε μέγεθος.

Κατανομή τιμών για ιδιότητες

Για να κάνουμε κατανομή των τιμών για τις ιδιότητες, αναλύσαμε τους τύπους τιμών των ιδιοτήτων και υπολογίσαμε το πλήθος των ιδιοτήτων με τιμές τύπου Literal (ακέραιοι, String, Boolean, κλπ.). Συγκεκριμένα, ελέγξαμε σε κάθε statement αν το object του είναι τύπου Literal. Σε περίπτωση που είναι,

και ο τύπος του είναι έγκυρος (έχει οριστεί σωστά, κλπ), τον αποθηκεύουμε στο `HashMap usesOfDatatypeProperties` κρατώντας την συχνότητα εμφάνισής του. Αυτό ουσιαστικά μας δείχνει πόσες φορές, από πόσες ιδιότητες, χρησιμοποιήθηκε ο τύπος.

```
// ΚΑΤΑΝΟΜΗ ΤΙΜΩΝ ΓΙΑ ΙΔΙΟΤΗΤΕΣ
if (statement.getObject() instanceof Literal) {
    Literal datatypeObjLit = (Literal) statement.getObject();
    IRI datatypeIRI = datatypeObjLit.getDatatype();
    if (datatypeIRI != null) {
        String datatypeObj = datatypeIRI.getLocalName();
        usesOfDatatypeProperties.put(datatypeObj, usesOfDatatypeProperties.getOrDefault(datatypeObj, defaultValue: 0) + 1);
    }
}
```

Αποτελέσματα:

Value Distribution for properties:	
Value type	# of Properties that use them
date	88
boolean	72
string	629
integer	6
decimal	29
int	10

Όπως παρατηρούμε, τα περισσότερα literal δεδομένα που υπάρχουν στο μοντέλο είναι τύπου String, ενώ έχουμε ελάχιστα δεδομένα τύπου integer.

Συχνότητα χρήσης συγκεκριμένων κλάσεων

Για να βρούμε την συχνότητα χρήσης συγκεκριμένων κλάσεων, υπολογίσαμε πόσες φορές χρησιμοποιούνται οι κλάσεις στο μοντέλο σε συγκεκριμένες ιδιότητες. Οι ιδιότητες που επιλέξαμε είναι οι πιο γνωστές και απαραίτητες, ιδιότητες που προϋπήρχαν και δεν τις ορίσαμε εμείς (δεν είναι στο χώρο του `astronomy` δηλαδή, είναι είτε `owl` είτε `rdf/rdfs`). Οι ιδιότητες στις οποίες χρησιμοποιούνται οι κλάσεις που μετρήσαμε είναι οι εξής:

- `RDF:TYPE`
- `RDF:SUBCLASSOF`
- `RDF:RANGE`
- `RDF:DOMAIN`
- `OWL:SOMEVALUESFROM`
- `OWL:ALLVALUESFROM`
- `OWL:HASVALUE`

Συγκεκριμένα, ελέγξαμε αν το object κάθε statement είναι τύπου IRI. Αν είναι IRI, αποκλείουμε με έλεγχο και την πιθανότητα να είναι Literal. Έτσι, συνεχίζουμε ελέγχοντας αν η ιδιότητα που έχει η κλάση κάθε φορά ανήκει σε μια από τις παραπάνω, και ανάλογα προσθέτουμε την κλάση που χρησιμοποιείται με αυτή στο `HashMap usesOfCertainClasses` όπου κρατάμε και την συχνότητα εμφάνισής της (άρα το πόσες φορές χρησιμοποιείται η κλάση με συγκεκριμένη ιδιότητα).

```

// ΣΥΧΝΟΤΗΤΑ ΧΡΗΣΗΣ ΣΥΓΓΕΚΡΙΜΕΝΩΝ ΚΛΑΣΕΩΝ
IRI pred = statement.getPredicate();
Value obj = statement.getObject();
String class_ = obj.stringValue();
String class_name = class_.substring( beginIndex: class_.lastIndexOf( ch: '#' ) + 1 );

if (obj instanceof IRI) {
    if (!(((IRI) obj).getNamespace().equals("http://www.w3.org/2001/XMLSchema#"))) {
        if (pred.toString().equals("http://www.w3.org/1999/02/22-rdf-syntax-ns#type")) {
            usesOfCertainClasses.put(class_name, usesOfCertainClasses.getOrDefault(class_name, defaultValue: 0) + 1);
        }
        else if (pred.toString().equals("http://www.w3.org/2000/01/rdf-schema#subClassOf")) {
            usesOfCertainClasses.put(class_name, usesOfCertainClasses.getOrDefault(class_name, defaultValue: 0) + 1);
        }
        else if (pred.toString().equals("http://www.w3.org/2000/01/rdf-schema#range")) {
            usesOfCertainClasses.put(class_name, usesOfCertainClasses.getOrDefault(class_name, defaultValue: 0) + 1);
        }
        else if (pred.toString().equals("http://www.w3.org/2000/01/rdf-schema#domain")) {
            usesOfCertainClasses.put(class_name, usesOfCertainClasses.getOrDefault(class_name, defaultValue: 0) + 1);
        }
        else if (pred.toString().equals("http://www.w3.org/2002/07/owl#someValuesFrom")) {
            usesOfCertainClasses.put(class_name, usesOfCertainClasses.getOrDefault(class_name, defaultValue: 0) + 1);
        }
        else if (pred.toString().equals("http://www.w3.org/2002/07/owl#allValuesFrom")) {
            usesOfCertainClasses.put(class_name, usesOfCertainClasses.getOrDefault(class_name, defaultValue: 0) + 1);
        }
        else if (pred.toString().equals("http://www.w3.org/2002/07/owl#hasValue")) {
            usesOfCertainClasses.put(class_name, usesOfCertainClasses.getOrDefault(class_name, defaultValue: 0) + 1);
        }
    }
}
}

```

Αποτελέσματα:

Usage Frequency of certain Classes			
Class	Frequency		

Galaxy	8	UnmannedSpacecraft	16
AstronomicalObject	100	SupermassiveBlackHole	10
Telescope	7	SymmetricProperty	2
SpaceStation	7	Sun	1
Moon	13	Comet	9
PlanetaryObject	45	LunarEclipse	2
SpaceArtifact	54	NegativePropertyAssertion	4
Eclipse	8	Class	177
Elliptical	2	WeatherSatellite	2
TransitiveProperty	2	SpaceObject	156
StellarBlackHole	2	Ontology	11
DwarfPlanet	4	LongPeriodComet	2
Nothing	1	GiantStar	3
NavigationSatellite	2	ContainerMembershipProperty	1
Datatype	41	CommunicationSatellite	1
AllDifferent	1	BlueSuperGiantStar	1
Container	3	Star	17
Literal	75	BlueGiantStar	10
StellarObject	27	CelestialBody	84
MainSequenceStar	3	Property	16
List	14	SuperGiantStar	4
Planet	18	MilkyWay	1
Thing	316	RedGiantStar	1
DatatypeProperty	42	Statement	3
Supernova	11	Spacecraft	16
ShortPeriodComet	3	MannedSpacecraft	4
ObjectProperty	137	ArtificialSatellite	17
RedSuperGiantStar	1	BlackHole	6
OntologyProperty	5	Spiral	2
Resource	196	AstronomicalPhenomenon	15
		Restriction	20
		SolarEclipse	2
		AnnotationProperty	9

Όπως παρατηρούμε, σε σχέση με το μέγεθος του μοντέλου, δεν χρησιμοποιούνται πολλές φορές κλάσεις με συγκεκριμένες ιδιότητες. Οι κλάσεις που χρησιμοποιούνται περισσότερο απ' όλες με τις ιδιότητες που προαναφέρθηκαν είναι οι Thing και Resource που ήδη υπήρχαν από το TopBraid, ακολουθεί η Class και από αυτές που εμείς κατασκευάσαμε είναι η SpaceObject.